

Náborová úloha

ML Trainee pro vyhledávání

Vypracoval

Jakub Čieško

Zvolené zadanie

Úloha č. 3 - analýza sentimentu recenze

Popis metód a výsledky

V úvode som načítal dáta pomocou pandas a spravil jednoduchú dátovú exploráciu pomocou klasických štatistických metód. Z tohto skúmania vyplynul vzťah dĺžky recenzie a finálneho sentimentu (rozdielne priemery dĺžky testu testované pomocou Kruskal-Wallis testu).

Všetky modely boli trénované a fitované na dáta zložené spojením textových polí *summary* a *text*. Finálny model bol trénovaný na augmentovaných dátach (náhodná výmena slov, vymazanie slov, náhrada synonymami a iné). Na augmentáciu boli využité len tie riadky, ktorých hodnota poľa *score* mala frekvenciu menej než 0,75-kvantil. Finálne dáta sú prístupné na hugging face pomocou odkazu v readme github repozitára alebo na konci tohto reportu. Kód na augmentáciu je dostupný v github repozitáry.

Ako základné modely boli zvolené Naive Bayes a logistická regresia. Oba modely využili celý tréningový dataset (train-test split 80-20), ktorý nebol balancovaný. Aj preto som využil 10fold cross validation, aby výsledky boli viac dôveryhodné. Jednotlivé texty boli tokenizované a rozdelené na unigramy a bigramy, pre ktoré bolo následne počítane TF-IDF skóre. Toto skóre bolo vstupom pre jednotlivé klasifikátory. Výsledky sú uvedené v tabuľke nižšie.

Zdrojový kód jednotlivých baseline modelov spolu s komentármi je dostupný v notebooku `baselines.ipynb`. Lepšie modely by mohli byť dosiahnuté najmä lepším preprocessingom (lemmatizácia, stemming a podobne) či zahrňaním väčšieho kontextu (napr. trigramy).

Ako výsledný model bol použitý encoder-only transformer RoBERTa, ktorý som dotrénoval na klasifikáciu (napriek tomu, že odporúčaná metrika RMSE bola skôr vhodná pre regresiu. Nevýhodou tohto prístupu [klasifikácie] je neexistujúci význam rozdielov medzi jednotlivými triedami, ktoré sú všetky považované za od seba rovnako „vzdialené“, tzn. label 1 je rovnako odlišný od 2 ako od 5. Ponímanie tejto úlohy ako regresie by takýto problém vyriešilo). Vytvoril som dva modely, ktoré sa odlišovali použitým datasetom a počtom tréningových epoch. Lepší model využil downsamplovaný augmentovaný dataset a bol trénovaný počas 6 epoch. Horší model využil downsamplovaný originálny dataset a bol trénovaný počas 3 epoch. Výsledky sú dostupné v tabuľke 1.

Lepšie výsledky by mohli byť dosiahnuté napríklad pomocou hyperparameter tuningu pomocou optuna alebo dlhším trénovaním, či lepším základným modelom. Zdrojový kód jednotlivých modelov aj s komentármi je dostupný v `roberta_main.ipynb` (lepší model) a `roberta3epochs.ipynb` (horší model).

Ako môžeme vidieť v tabuľke 1, už základné metódy dosahujú dobrú accuracy, táto metrika však nie je veľmi vhodná, nakoľko je dataset značne nevyvážený. Preto som do výslednej metricky pridal aj F1-skóre, ktoré lepšie vyjadruje schopnosť modelu generalizovať naprieč triedami. Práve v tom je ďaleko najlepší model RoBERTa (6 epoch), ktorý bol trénovaný na vyrovnanom datasete, ktorý bol navyše augmentovaný, čo zlepšuje schopnosť modelu zovšeobecňovať.

Model	Accuracy	RMSE	F1 Macro	F1 Micro
TF-IDF + Logistic Regression	0.7139	0.8492	0.5960	0.7139
TF-IDF + Naive Bayes	0.7212	1.1220	0.4235	0.7212
RoBERTa (6 epoch)	0.8020	0.5390	0.8025	0.8020
RoBERTa (3 epoch)	0.7202	0.6321	0.7198	0.7202

Tabuľka 1: Výsledky jednotlivých modelov

Jednotlivé výsledky každého modelu sú dostupné v priechinkoch metrics a reports v github repository.

Odkazy na zdrojové kódy a dáta

Zdrojové kódy sú dostupné v github repository:

<https://github.com/JakubCiesko/sentiment-analysis-amazon>

Augmentované dáta sú dostupné v hugging face repository:

https://huggingface.co/datasets/maennyn/amazon_fine_foods_augmented_q75

Natrénované RoBERTa modely sú tiež dostupné v hugging face repository:

<https://huggingface.co/maennyn/roberta-amazon-finefood-sentiment6e>

<https://huggingface.co/maennyn/roberta-amazon-finefood-sentiment>